

Plateforme SaaS RAG pour Generation de Rapports Academiques

Architecture complete, detaillee jusqu'au niveau fichier et module, concue pour le vibecoding avec Claude Code.

Stack Next.js 14, PostgreSQL + pgvector, Claude Sonnet, et pipeline RAG optimise pour 25 utilisateurs en phase test.

Stack : Next.js 14 + TypeScript + Tailwind + shadcn/ui

Base de donnees : PostgreSQL (Neon) + pgvector

LLM : Claude Sonnet (Anthropic API)

Phase : Test ~25 utilisateurs

RAG

TIPTAP

BULLMQ

STRIPE

PGVECTOR

1. Vue d'ensemble et stack technique3

1.1 Contexte et objectif du produit3

1.2 Stack technique definitif3

1.3 Architecture systeme4

2. Arborescence projet (Next.js App Router)5

2.1 Structure /lib (logique metier)6

2.2 Structure /components (composants UI)7

3. Schema de donnees complet (Drizzle ORM)7

3.1 Enumerations7

3.2 Tables principales8

3.3 Details des tables8

4. Pipeline RAG (coeur du produit)9

4.1 Phase 1 : Indexation offline du corpus9

4.2 Phase 2 : Generation du sommaire10

4.3 Phase 3 : Generation du rapport complet10

5. Pipeline detaille par etape11

5.1 Etape A : Onboarding projet11

5.2 Etape B : Generation sommaire11

5.3 Etape C : Edition iterative du sommaire11

5.4 Etape D : Generation rapport complet11

5.5 Etape E : Editeur split-view11

6. Gestion des quotas et Stripe Billing12

6.1 Middleware de verification des quotas12

6.2 Tiers d'abonnement suggeres13

6.3 Webhook Stripe13

7. Export final (DOCX et PDF)13

7.1 Export DOCX13

7.2 Export PDF14

8. Points d'attention et securite **14**

8.1 Confidentialite et isolation des donnees 14

8.2 Suivi des couts API 14

8.3 Corpus de reference : conformite legale 14

8.4 Rate limiting et securite API 14

9. Ordre de vibecoding recommande **15**

9.1 Estimation de couts (25 utilisateurs en test) 15

Upstash Redis	0-5 \$	Pay-per-use, negligeable a 25 users
Cloudflare R2	0-2 \$	10 Go gratuit, pas d'egress fees
Anthropic Claude API	10-30 \$	Variable selon usage, loguer par user
Voyage AI Embeddings	2-5 \$	Indexation initiale + requetes
Stripe	0 \$	Pas de frais tant que pas de transactions reelles
Sentry (Free)	0 \$	5 000 events/mois gratuit
Total estime	12-42 \$/mois	Hors API Claude a l'usage reel

Tableau 8 : Estimation des couts mensuels en phase test